

Control — App de IA/ML en contenedor

Modelos en Producción · UNI 2026 · Rodrigo López Vera

Objetivo

Construir una pequeña **app de IA/ML** que reciba una **entrada** (p. ej. una pregunta o un texto) y devuelva una **respuesta** (una respuesta de AI o una predicción), empaquetarla en una **imagen Docker**, y entregármela para que yo la levante y la pruebe.

Qué construir

Un servicio que recibe una **entrada** y devuelve una **salida** usando IA/ML. Tú eliges el tema y el enfoque. No tiene que ser complejo; tiene que **funcionar y correr**.

Proyectos sugeridos (elige uno)

- **API como la de clase:** FastAPI con un endpoint que recibe una pregunta y responde (RAG con un LLM sobre tus propios documentos).
- **QA sobre una página web:** indexa el contenido de una web y responde preguntas sobre ella.
- **Problema clásico de ML:** entrena o usa un modelo (p. ej. clasificador de sentimiento/spam) y exponlo como API que "responde" a una entrada.

Definición de "Hecho"

1. Va empaquetado en una **imagen Docker** que arranca con **un solo comando**.
2. Incluye un **README** con: cómo construir o cargar la imagen, cómo correrla, y **1 ejemplo** de entrada → respuesta.
3. Si usas una API key (Gemini, OpenAI, etc.), se **inyecta en runtime** (`-e API_KEY=...`), **nunca** dentro de la imagen.
4. Me entregas la imagen **de cualquier forma**: link a GHCR, archivo `.tar` (`docker save`), o un repo con el Dockerfile.

Evaluación

Sigo tu README. Normalmente: `docker run --rm -p 8000:8000 -e API_KEY=... TU_IMAGEN` (o `docker load` si me mandas un `.tar`). Luego pruebo tu ejemplo y un par de entradas más. **Si no arranca siguiendo tu README, no puedo evaluarlo: prioriza que corra.**

Puntos extra (opcional, suma sobre lo visto en clase)

- Repo en **Git** limpio: `.gitignore` + `.dockerignore` , **sin secretos**.
- **Dockerfile de producción:** base `slim` + `uv` con lockfile + orden de capas.
- Imagen publicada en **GHCR**.
- **CI con GitHub Actions** (lint/test/build/push, tag por `SHA`).
- **Tests** (`pytest`), **lint** (`ruff`) o **pre-commit**; o `/metrics` .
- Cualquier otra práctica vista en clase (Kubernetes, observabilidad, MLflow).

Rúbrica (20 pts)

Criterio	Pts
La imagen arranca con un solo <code>docker run</code>	6
El modelo/IA funciona: responde de forma correcta y pertinente a la entrada	6
README claro (construir/correr + 1 ejemplo)	3
Puntos extra (Git, GHCR, CI, Dockerfile slim/uv, tests/lint, etc.)	5

Entrega

- **Fecha límite:** 13-06-26
- **Modalidad:** individual
- **Canal:** como prefieras (link GHCR, `.tar` , o link al repo).